

Premissas e Decisões — Diagnóstico de Turnover Grupo Avelar

Documento técnico que registra as escolhas de tratamento de dados e as premissas de negócio por trás dos números do dashboard. Objetivo: tornar o diagnóstico auditável e reproduzível.

1. Origem dos dados

- **Fonte:** dataset público **IBM HR Analytics Employee Attrition** (Kaggle), 1.470 colaboradores, 35 colunas, sem dados pessoais reais.
- **Cenário:** o **Grupo Avelar** é uma rede varejista **fictícia**. Os dados são reais (do dataset IBM), mas a narrativa de varejo é simulada para fins de portfólio.
- **Qualidade da base:** verificado **0 valores nulos** e **0 chaves EmployeeNumber duplicadas**. Não foi necessário imputar ou descartar registros por ausência de dados.

2. Definição de turnover

- Turnover é medido pela coluna **Attrition** (Yes/No): **237 desligamentos** em 1.470 colaboradores = **16,1%**.
- **Limitação documentada:** o dataset **não distingue saída voluntária de involuntária**. Embora o pedido da diretoria fale em "turnover voluntário", a base só traz o desligamento de forma binária. Todos os desligamentos são tratados como uma população única, e isso está explicitado para não superinterpretar o número.

3. Tratamento aplicado (Python / pandas)

Decisão	O que foi feito	Por quê
Colunas constantes	Descartadas EmployeeCount (=1), Over18 (=Y) e StandardHours (=80)	Não têm variação nem valor analítico
Fragmentação em 3 fontes	A base única foi dividida em Cadastro/Folha, Avaliação e Clima, ligadas por EmployeeNumber, e depois re-unida via join	Simula a integração de sistemas reais de uma empresa (ver 02-modelo-de-dados.md)
Validação do join	<code>merge(..., validate="one_to_one")</code>	Garante que nenhuma linha foi perdida ou duplicada na reunião das fontes

Nulos	Nenhum tratamento necessário	A base não possui valores ausentes
-------	------------------------------	------------------------------------

4. Premissas de cálculo das métricas

- **Custo de turnover:** premissa de **50% do salário anual por reposição** (recrutamento + treinamento + produtividade perdida). Operacionalmente: $\text{custo} = 0,5 \times (\text{salário mensal} \times 12) = 6 \times \text{MonthlyIncome}$. MonthlyIncome é tratado como salário mensal em R\$.
- Custo total estimado: **R\$ 6,8 mi** · Custo médio por desligamento: **R\$ 28,7 mil**.
- **Índice de satisfação:** média de JobSatisfaction (escala 1–4) **normalizada para 0–10**: $(\text{média} / 4) \times 10$. Resultado geral: **6,8/10**.
- **Tempo médio de permanência:** média de YearsAtCompany = **7,0 anos**.
- **Faixas salariais:** Até R\$ 3 mil · R\$ 3–5 mil · R\$ 5–8 mil · R\$ 8–12 mil · Acima de R\$ 12 mil.
- **Faixas etárias:** Até 25 · 26–35 · 36–45 · 46–55 · 56+.
- **Classificação de status do departamento:** Crítico $\geq 18\%$ · Atenção $\geq 14\%$ · Estável $< 14\%$ de turnover.
- **Classificação de risco do cargo:** Alto $\geq 20\%$ · Médio $\geq 12\%$ · Baixo $< 12\%$ de turnover.
- **Cenário de economia:** redução hipotética de **20%** no turnover -> economia de **R\$ 1,4 mi/ano** (~47 desligamentos evitados).

5. De-para de rótulos (categorias técnicas -> varejo)

O dataset IBM é de uma empresa de tecnologia/pesquisa. Para manter a narrativa do Grupo Avelar (varejo), as categorias foram **renomeadas de forma documentada**. **As taxas e valores permanecem 100% reais** — apenas os rótulos mudam.

Departamentos

IBM (original)	Grupo Avelar
Sales	Operações de Loja
Research & Development	Logística & CD
Human Resources	Administrativo & Suporte

Cargos (atribuídos por nível e rotatividade plausíveis)

IBM (original)	Grupo Avelar
Sales Representative	Operador de Caixa

Laboratory Technician	Repositor
Human Resources	Auxiliar Administrativo
Sales Executive	Vendedor
Research Scientist	Auxiliar de Logística
Healthcare Representative	Supervisor de Loja
Manufacturing Director	Coordenador de CD
Manager	Gerente de Loja
Research Director	Gerente Regional

6. Elementos do design ajustados por limitação dos dados

O layout de design previa três visuais que o dataset **não suporta**. Em vez de inventar dados, eles foram **substituídos por alternativas 100% reais**:

Visual original (design)	Por que não dá	Substituído por
Evolução do turnover por trimestre	O dataset é uma fotografia única, sem datas	Turnover por faixa etária
Saída voluntária × involuntária	Attrition é binário, sem tipo	Desligamentos por nível de cargo
Composição do custo (recrut./trein./...)	Não há dado de composição	Custo de turnover por departamento

Pelo mesmo motivo, o seletor de período do design (filtro de ano) foi substituído por um **filtro de Departamento**, que é uma dimensão real e funcional na base.

Próximos documentos: *02-modelo-de-dados.md* (como as fontes se relacionam) e *03-resumo-executivo.md* (resposta de 1 página à diretoria).